شرح کد

در ابتدا کتابخانه های مورد نیاز که در اینجا از numpy و pandas استفاده کرده ایم را import می کنیم.

سپس فایل مربوط به داده های فیلم ها(movies.csv) و نمره ها(ratings.csv) را توسط کتابخانه pandas مطابق شکل زیر می خوانیم.

```
movies_df = pd.read_csv("D:/temp/movies.csv")
ratings_df = pd.read_csv("D:/temp/ratings.csv")

movies_df.head()
```

	movieId	title	genres
0	1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
1	2	Jumanji (1995)	Adventure|Children|Fantasy
2	3	Grumpier Old Men (1995)	Comedy|Romance
3	4	Waiting to Exhale (1995)	Comedy|Drama|Romance
4	5	Father of the Bride Part II (1995)	Comedy

همانطور که در چند داده ابتدایی مربوط به فایل فیلم ها مشاهده می شود، مشکلی که وجود دارد این است که در ستون مربوط به title سال انتشار فیلم ها هم در داخل پرانتز نوشته شده است. ما قصد داریم که ستون جدیدی به نام year ایجاد کنیم و سال انتشار فیلم ها را به آن ستون انتقال دهیم و همچنین سال انتشار را از ستون مربوط به title حذف کنیم که برای اینکار به صورت زیرعمل میکنیم.

```
movies_df['year'] = movies_df.title.str.extract('(\(\d\d\d\d\))', expand=False)
movies_df['year'] = movies_df.year.str.extract('(\d\d\d\d)', expand=False)
movies_df['title'] = movies_df.title.str.replace('(\(\d\d\d\d\))', '')
movies_df['title'] = movies_df.title.apply(lambda x: x.strip())
movies_df.head()
```

```
C:\Users\rqase\AppData\Local\Temp/ipykernel_13960/1422495819.py:3: FutureWarning: The default value of regex will change from T
rue to False in a future version.
  movies_df['title'] = movies_df.title.str.replace('(\(\d\d\d\d\))', '')
```

	movieId	title	genres	year
0	1	Toy Story	Adventure|Animation|Children|Comedy|Fantasy	1995
1	2	Jumanji	Adventure|Children|Fantasy	1995
2	3	Grumpier Old Men	Comedy|Romance	1995
3	4	Waiting to Exhale	Comedy|Drama|Romance	1995
4	5	Father of the Bride Part II	Comedy	1995

در واقع همانطور که در کد بالا نشان داده شده است ما از regex استفاده کردیم. در واقع ما توسط خط اول به برنامه گفتیم که عبارت \(\d\d\d\d\) یعنی عبارتی که شامل پرانتز باز و سپس 4 تا عدد و سپس پرانتز بسته است را از ستون مربوط به title جدا کند و آنرا در ستون جدید به نام year قرار دهد و در سطر دوم پرانتز را از ستون مربوط به year حذف کردیم و در خط سوم مقدار سال را از ستون title حذف کردیم و به جای آن مقدار ‘ ’ را قرار دادیم و در انتها مقادیر مربوط به ستون title را strip() کردیم. حال داده هایمان به شکلی که در جدول بالا نشان داده شده است در آمد.

توسط کد زیر علامت "|" را از ستون مربوط به ژانر ها بر داشته و مقادیر هر خانه آن ستون را در لیستی قرار دادیم.

```
In [50]: movies_df['genres'] = movies_df.genres.str.split('|')
         movies_df.head()
```

Out[50]:

	movieId	title	genres	year
0	1	Toy Story	[Adventure, Animation, Children, Comedy, Fantasy]	1995
1	2	Jumanji	[Adventure, Children, Fantasy]	1995
2	3	Grumpier Old Men	[Comedy, Romance]	1995
3	4	Waiting to Exhale	[Comedy, Drama, Romance]	1995
4	5	Father of the Bride Part II	[Comedy]	1995

حال توسط کد زیر dataframe جدید را به نام moviesWithGenres_df ایجاد کردیم و به آن به ازای هر ژانری که در داده های movies_df وجود داشت یک ستون به آن اضافه کردیم(توسط حلقه for).

وقتی که حلقه for اجرا می شود در بعضی از خانه های مربوط به هر ژانر جدیدی که ایجاد میشود تعدادی از آن ها بدون مقدار می مانند.(زیرا طبیعتا هر فیلم شامل همه ژانر ها نیست!)

برای رفع این مشکل از fillna(0) استفاده کردیم تا مقادیری را که مقدار nan دارند را برابر با 0 قرار دهیم.

```
moviesWithGenres_df = movies_df.copy()

for index, row in movies_df.iterrows():
    for genre in row['genres']:
        moviesWithGenres_df.at[index, genre] = 1

moviesWithGenres_df = moviesWithGenres_df.fillna(0)
moviesWithGenres_df.head()
```

	movieId	title	genres	year	Adventure	Animation	Children	Comedy	Fantasy	Romance	...	Horror	Mystery	Sci-Fi	War	Musical	Documentary	If
0	1	Toy Story	[Adventure, Animation, Children, Comedy, Fantasy]	1995	1.0	1.0	1.0	1.0	1.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	
1	2	Jumanji	[Adventure, Children, Fantasy]	1995	1.0	0.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	
2	3	Grumpier Old Men	[Comedy, Romance]	1995	0.0	0.0	0.0	1.0	0.0	1.0	...	0.0	0.0	0.0	0.0	0.0	0.0	
3	4	Waiting to Exhale	[Comedy, Drama, Romance]	1995	0.0	0.0	0.0	1.0	0.0	1.0	...	0.0	0.0	0.0	0.0	0.0	0.0	
4	5	Father of the Bride Part II	[Comedy]	1995	0.0	0.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	

5 rows × 24 columns

حال به سراغ داده های rating.csv که آنرا در ratings_df قرار دادیم می رویم. همانطور که در شکل زیر مشاهده می شود ستونی به نام timestamp وجود دارد.

```
ratings_df.head()
```

	userId	movieId	rating	timestamp
0	1	1	4.0	964982703
1	1	3	4.0	964981247
2	1	6	4.0	964982224
3	1	47	5.0	964983815
4	1	50	5.0	964982931

ولی در این روش ما نیازی به داده های این ستون که در واقع زمان ثبت نمره به فیلم را نشان می دهند نداریم و آن را مطابق دستور زیر از ratings_df حذف می کنیم.

```
ratings_df = ratings_df.drop("timestamp", 1)
ratings_df.head()
```

```
C:\Users\rqase\AppData\Local\Temp/ipykernel_13960/254338903.py:1: FutureWarning: In a future version of pandas all arguments of
DataFrame.drop except for the argument 'labels' will be keyword-only
  ratings_df = ratings_df.drop("timestamp", 1)
```

	userId	movieId	rating
0	1	1	4.0
1	1	3	4.0
2	1	6	4.0
3	1	47	5.0
4	1	50	5.0

حال فرض می کنیم داده های ورودی توسط کاربری را که قصد داریم به او فیلم هایی را پیشنهاد کنیم مطابق شکل زیر باشد. ما آن را به صورت یک dataframe در می آوریم.

In [54]:
```
userInput = [
    {'title':'Breakfast Club, The', 'rating':5},
    {'title':'Toy Story', 'rating':3.5},
    {'title':'Jumanji', 'rating':2},
    {'title':'Pulp Fiction', 'rating':5},
    {'title':'Akira', 'rating':4.5}
]

inputMovies = pd.DataFrame(userInput)
inputMovies
```

Out[54]:

	title	rating
0	Breakfast Club, The	5.0
1	Toy Story	3.5
2	Jumanji	2.0
3	Pulp Fiction	5.0
4	Akira	4.5

توسط کد زیر ما Id مربوط به هر فیلمی را که کاربر به آنها رای داده را نیز وارد dataframe مربوط به آن که توسط کد بالا تشکیل شد قرار می دهیم. در نتیجه ستون movieId به آن اضافه می شود.

```
In [55]: inputId = movies_df[movies_df['title'].isin(inputMovies['title'].tolist())]
         inputMovies = pd.merge(inputId, inputMovies)
         inputMovies = inputMovies.drop('genres', 1).drop('year', 1)
         inputMovies
```

```
C:\Users\rqase\AppData\Local\Temp/ipykernel_13960/2584586099.py:3: FutureWarning: In a future version of pandas all arguments o
f DataFrame.drop except for the argument 'labels' will be keyword-only
  inputMovies = inputMovies.drop('genres', 1).drop('year', 1)
```

Out[55]:

	movieId	title	rating
0	1	Toy Story	3.5
1	2	Jumanji	2.0
2	296	Pulp Fiction	5.0
3	1274	Akira	4.5
4	1968	Breakfast Club, The	5.0

ما همینطور نیاز داریم تا ستون های مربوط به ژانرها را هم به dataframe بالا اضافه کنیم برای این کار از moviesWithGenres_df و از ستون moviId آن، آنهایی را انتخاب میکنیم که moviId آنها با فیلم های inputMovies برابر باشد.که در شکل زیر نشان داده شده است.

```
In [56]: userMovies = moviesWithGenres_df[moviesWithGenres_df['movieId'].isin(inputMovies['movieId'].tolist())]
         userMovies
```

Out[56]:

	movieId	title	genres	year	Adventure	Animation	Children	Comedy	Fantasy	Romance	...	Horror	Mystery	Sci-Fi	War	Musical	Documentary
0	1	Toy Story	[Adventure, Animation, Children, Comedy, Fantasy]	1995	1.0	1.0	1.0	1.0	1.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0
1	2	Jumanji	[Adventure, Children, Fantasy]	1995	1.0	0.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0
257	296	Pulp Fiction	[Comedy, Crime, Drama, Thriller]	1994	0.0	0.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0
973	1274	Akira	[Action, Adventure, Animation, Sci-Fi]	1988	1.0	1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	1.0	0.0	0.0	0.0
1445	1968	Breakfast Club, The	[Comedy, Drama]	1985	0.0	0.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0

5 rows × 24 columns

حال توسط کد زیر اندیس های جدول بالا را reset می کنیم. و همینطور ستون های movieId و title و genre و year را حذف می کنیم تا اعمال ضرب ماتریسی را روی آن انجام دهیم. و اسم dataframe حاصل را userGenreTable می گذاریم.

```
In [58]: userMovies = userMovies.reset_index(drop=True)
         userGenreTable = userMovies.drop('movieId', 1).drop('title', 1).drop('genres', 1).drop('year', 1)
         userGenreTable
```

```
C:\Users\rqase\AppData\Local\Temp/ipykernel_13960/638483878.py:2: FutureWarning: In a future version of pandas all arguments of
DataFrame.drop except for the argument 'labels' will be keyword-only
  userGenreTable = userMovies.drop('movieId', 1).drop('title', 1).drop('genres', 1).drop('year', 1)
```

Out[58]:

	Adventure	Animation	Children	Comedy	Fantasy	Romance	Drama	Action	Crime	Thriller	Horror	Mystery	Sci-Fi	War	Musical	Documentary	IMAX	Wes
0	1.0	1.0	1.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
1	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
2	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
3	1.0	1.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	
4	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	

حال نگاهی به امتیاز هایی که کاربر به فیلم های مورد نظرش داده می اندازیم:

```
In [59]: inputMovies['rating']

Out[59]: 0    3.5
         1    2.0
         2    5.0
         3    4.5
         4    5.0
         Name: rating, dtype: float64
```

توسط کد زیر این مقادیر را در در ماتریس userGenreTable ضرب می کنیم تا لیست userProfile که در فایل "شرح روش" به آن اشاره کردیم بدست آید.(البته هنوز آن را نرمال نکردیم این کار را در کدهای بعدی انجام داده ام.)

```
In [60]: userProfile = userGenreTable.transpose().dot(inputMovies['rating'])
         userProfile

Out[60]: Adventure             10.0
         Animation              8.0
         Children               5.5
         Comedy                13.5
         Fantasy                5.5
         Romance                0.0
         Drama                 10.0
         Action                 4.5
         Crime                  5.0
         Thriller               5.0
         Horror                 0.0
         Mystery                0.0
         Sci-Fi                 4.5
         War                    0.0
         Musical                0.0
         Documentary            0.0
         IMAX                   0.0
         Western                0.0
         Film-Noir              0.0
         (no genres listed)     0.0
         dtype: float64
```

حالا به صورت زیر genreTable را از moviesWithGenres_df که قبلا تشکیل دادیم بدست می آوریم و همینطور در خط اول کد توجه می کنیم که index را برابر با movieId قرار دادیم که در ادامه بکارمان می آید. و ستون های movieId و title و genre و year را از آن حذف می کنیم. در واقع genreTable ماتریسی فیلم هایی است که باید از آن تعدادی فیلم را به کاربر مورد نظرمان پیشنهاد کنیم.

In [62]:
```
genreTable = moviesWithGenres_df.set_index(moviesWithGenres_df['movieId'])

genreTable = genreTable.drop('movieId', 1).drop('title', 1).drop('genres', 1).drop('year', 1)
genreTable.head()
```

```
C:\Users\rqase\AppData\Local\Temp/ipykernel_13960/625636090.py:3: FutureWarning: In a future version of pandas all arguments of
DataFrame.drop except for the argument 'labels' will be keyword-only
  genreTable = genreTable.drop('movieId', 1).drop('title', 1).drop('genres', 1).drop('year', 1)
```

Out[62]:

	Adventure	Animation	Children	Comedy	Fantasy	Romance	Drama	Action	Crime	Thriller	Horror	Mystery	Sci-Fi	War	Musical	Documentary	IMA
movieId																	
1	1.0	1.0	1.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.
2	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.
3	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.
4	0.0	0.0	0.0	1.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.
5	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.

حال توسط کد زیر recommendationTable_df را بدست می آوریم به این صورت که genreTable را در userProfile ضرب میکنیم و حاصل جمع عناصر هر سطر را بدست می آوریم و حاصل را بر جمع عناصر userProfile تقسیم می کنیم تا عمل نرمال سازی را هم لحاظ کرده باشیم.

In [66]:
```
recommendationTable_df = ((genreTable*userProfile).sum(axis=1))/(userProfile.sum())
recommendationTable_df.head()
```

Out[66]:
```
movieId
1    0.594406
2    0.293706
3    0.188811
4    0.328671
5    0.188811
dtype: float64
```

برای اینکه بهترین پیشنهاد را به کاربر بدهیم recommendationTable_df را به صورت نزولی مرتب می کنیم:

```
In [67]: recommendationTable_df = recommendationTable_df.sort_values(ascending=False)
         recommendationTable_df.head()

Out[67]: movieId
         134853    0.734266
         148775    0.685315
         117646    0.678322
         6902      0.678322
         81132     0.671329
         dtype: float64
```

سپس هر تعداد فیلم را که بخواهیم می توانیم از recommendationTable_df انتخاب و به کاربر پیشنهاد کنیم. فقط باید توجه کنیم که در بالا ما movieId فیلم ها را داریم که باید از روی آن اسم فیلم را بدست بیاوریم. برای اینکار به شکل زیر عمل میکنیم. که اسم 15 فیلمی را که احتمالا مورد پسند کاربر هستند به او پیشنهاد میکنیم:

```
In [70]: movies_df.loc[movies_df['movieId'].isin(recommendationTable_df.head(15).keys())]

Out[70]:
```

	movieId	title	genres	year
559	673	Space Jam	[Adventure, Animation, Children, Comedy, Fanta...	1996
1390	1907	Mulan	[Adventure, Animation, Children, Comedy, Drama...	1998
2250	2987	Who Framed Roger Rabbit?	[Adventure, Animation, Children, Comedy, Crime...	1988
4631	6902	Interstate 60	[Adventure, Comedy, Drama, Fantasy, Mystery, S...	2002
5490	26340	Twelve Tasks of Asterix, The (Les douze travau...	[Action, Adventure, Animation, Children, Comed...	1976
5819	32031	Robots	[Adventure, Animation, Children, Comedy, Fanta...	2005
6047	40339	Chicken Little	[Action, Adventure, Animation, Children, Comed...	2005
6448	51939	TMNT (Teenage Mutant Ninja Turtles)	[Action, Adventure, Animation, Children, Comed...	2007
7441	81132	Rubber	[Action, Adventure, Comedy, Crime, Drama, Film...	2010
8349	108540	Ernest & Célestine (Ernest et Célestine)	[Adventure, Animation, Children, Comedy, Drama...	2012
8357	108932	The Lego Movie	[Action, Adventure, Animation, Children, Comed...	2014
8597	117646	Dragonheart 2: A New Beginning	[Action, Adventure, Comedy, Drama, Fantasy, Th...	2000
8806	130520	Home	[Adventure, Animation, Children, Comedy, Fanta...	2015
8900	134853	Inside Out	[Adventure, Animation, Children, Comedy, Drama...	2015
9169	148775	Wizards of Waverly Place: The Movie	[Adventure, Children, Comedy, Drama, Fantasy, ...	2009

این پروژه در واقع پروژه نهایی مربوط به بخش recommender system دوره آنلاینی بود که در در چند هفته قبل خریداری کردم و گذراندم. و فایل داده را در دوره در اختیار بنده قرار داده بودند و از داده های سایت imdb گرفته شده بود.

سپاس از توجه شما